Greed Route — ระบบแนะนำหนังสือออนไลน์

Book Recommendation System for Greed Route Platform

รายวิชา: 2603522 Recommender Systems
ภาคการศึกษา: 2/2568
ผู้สอน: รองศาสตราจารย์ ดร.วรสิทธิ์ ชูชัยวัฒนะ

จัดทำโดย:

ชื่อ-สกุล	รหัสนิสิต
(ชื่อสมาชิก 1)	(รหัสนิสิต)
(ชื่อสมาชิก 2)	(รหัสนิสิต)

วันที่ส่ง: 24 เมษายน 2569

Chapter 1: Introduction

1.1 Background and Motivation

ในยุคที่ข้อมูลหนังสือมีมากมายบนแพลตฟอร์มออนไลน์ ผู้อ่านมักประสบปัญหาในการเลือกหนังสือที่ตรงกับความสนใจของตนเอง — ปรากฏการณ์ที่เรียกว่า **Information Overload** โครงงานนี้จึงพัฒนาระบบแนะนำหนังสือสำหรับแพลตฟอร์ม **Greed Route** ซึ่งเป็นเว็บแอปพลิเคชันสไตล์ Goodreads ที่รองรับภาษาไทยและภาษาอังกฤษ โดยมีเป้าหมายเพื่อมอบประสบการณ์การค้นหาหนังสือที่เป็นส่วนตัวและราบรื่นให้แก่ผู้ใช้

Greed Route ถูกออกแบบเป็น multi-sided platform ที่เชื่อมต่อผู้อ่าน สำนักพิมพ์ และร้านหนังสือเข้าด้วยกัน โดยแพลตฟอร์มประกอบด้วยฟีเจอร์หลัก ได้แก่:

- **ระบบแนะนำส่วนตัว** (Recommended for You) — แนะนำหนังสือตามพฤติกรรมและความชอบของผู้ใช้
- **ระบบสำรวจ** (Explore, New Releases, Trending) — ให้ผู้ใช้ค้นพบหนังสือใหม่ ๆ
- **ชุมชน** (Groups, Discussions, Quotes) — ส่งเสริมการมีปฏิสัมพันธ์ระหว่างผู้อ่าน
- **ชั้นหนังสือส่วนตัว** (My Books) — ติดตามการอ่านและจัดการรายการหนังสือ
- **Choice Awards** — โหวตหนังสือยอดเยี่ยมแห่งปี

ระบบแนะนำที่พัฒนาขึ้นใช้ข้อมูลจากพฤติกรรมการใช้งานจริงของผู้ใช้ (user interaction events) ร่วมกับข้อมูลหนังสือ (content features) เพื่อสร้างคำแนะนำที่ผสมผสานหลายแนวทาง ได้แก่ Collaborative Filtering, Content-Based Filtering, Popularity-Based Filtering และ Hybrid Approach

1.2 Objectives

1. ออกแบบและสร้างฐานข้อมูลสำหรับระบบแนะนำหนังสือ ที่ครอบคลุมข้อมูลผู้ใช้ หนังสือ พฤติกรรมการใช้งาน และ recommendation log
2. พัฒนาและประเมินผลอัลกอริทึมระบบแนะนำหลายรูปแบบ ได้แก่ Collaborative Filtering, Content-Based Filtering, Popularity-Based และ Hybrid
3. สร้าง Prototype ของเว็บแอปพลิเคชัน **Greed Route** ที่แสดงผลระบบแนะนำแบบ end-to-end
4. ประเมินประสิทธิผลของระบบแนะนำด้วย Precision@K, Recall@K, NDCG, CTR และ Coverage

1.3 Scope of the Study

- **จำนวนหนังสือ:** 6,000 เล่ม ครอบคลุม 24 หมวดหมู่หลัก (genre) และ 93 หมวดย่อย (subgenre)
- **จำนวนผู้ใช้:** 1,000 คน พร้อม demographic profile ครบถ้วน
- **จำนวน interaction events:** ~200,000+ แถว (user_book_event) ครอบคลุม 9 ระดับ intent
- **จำนวน recommendation log:** 50,000 แถว จาก 4 อัลกอริทึม
- **ช่วงเวลาข้อมูล:** 1 มกราคม 2024 ถึง 31 ธันวาคม 2025
- **เว็บแอปพลิเคชัน:** 14 หน้า HTML แบบ static prototype พร้อมระบบ bilingual (TH/EN)
- **LLM:** Google Gemini API สำหรับ generate book descriptions และ Thai review messages

1.4 Methodology Overview

โครงงานนี้ดำเนินการตามขั้นตอนหลัก 6 ขั้น:

1. **Database Design** — ออกแบบ schema ครอบคลุมตาราง 18 ตาราง ตามหลัก star schema (fact + dimension)
2. **Data Generation** — สร้างข้อมูลจำลองที่สมจริง ด้วย Python + Gemini API

3. **Data Preparation** — สร้าง merged/analytical tables สำหรับแต่ละอัลกอริทึม
4. **Model Development** — พัฒนาอัลกอริทึม 4 แบบ: Collaborative, Content-Based, Popularity, Hybrid
5. **Evaluation** — ประเมินผลด้วย offline metrics (Precision@K, Recall@K, NDCG, CTR)
6. **Prototype** — สร้างเว็บแอปพลิเคชัน Greed Route เพื่อสาธิตการทำงานของระบบ

1.5 Expected Contributions

- **Practical:** ระบบแนะนำ end-to-end ที่ใช้งานได้จริงบน Greed Route platform พร้อม recommendation pipeline
- **Academic:** เปรียบเทียบประสิทธิภาพ Collaborative vs. Content-Based vs. Hybrid ในบริบทหนังสือภาษาไทย
- **Technical:** Database schema 18 ตารางที่ออกแบบสำหรับ recommendation system โดยเฉพาะ พร้อม merged tables 6 ตารางสำหรับแต่ละ use case

---

Chapter 2: Related Concepts and Algorithms

บทนี้อธิบายแนวคิดพื้นฐาน อัลกอริทึม และเทคนิคที่นำมาประยุกต์ใช้ในระบบแนะนำหนังสือ Greed Route โดยเน้นความเชื่อมโยงกับข้อมูลและฟีเจอร์ที่มีอยู่จริงในแพลตฟอร์ม

2.1 Recommender System Overview

Recommender System คือระบบที่กรองข้อมูลจำนวนมาก เพื่อแนะนำ item ที่ผู้ใช้น่าจะสนใจที่สุด โดยทั่วไปแบ่งออกเป็น 3 แนวทางหลัก:

แนวทาง	วิธีการ	จุดแข็ง	จุดอ่อน
Collaborative Filtering	ใช้ rating patterns ของผู้ใช้ที่คล้ายกัน	ค้นพบ item ใหม่ที่ไม่เคยเห็น	Cold-start problem
Content-Based Filtering	ใช้ features ของ item (genre, tags, description)	ทำงานได้กับ user ใหม่	จำกัดอยู่ใน content ที่คล้ายกัน
Hybrid	รวม Collaborative + Content-Based	ลบจุดอ่อนของแต่ละแนวทาง	ซับซ้อนกว่า

2.2 Collaborative Filtering

2.2.1 User-Based Collaborative Filtering

ค้นหาผู้ใช้ที่มี rating pattern คล้ายกับผู้ใช้เป้าหมาย แล้วแนะนำหนังสือที่ผู้ใช้คล้ายกันชอบแต่ผู้ใช้เป้าหมายยังไม่เคยอ่าน

Similarity measure: Cosine Similarity

$$\text{sim}(u, v) = \frac{\sum_{i \in I_{uv}} r_{ui} \cdot r_{vi}}{\sqrt{\sum_{i \in I_{uv}} r_{ui}^2} \cdot \sqrt{\sum_{i \in I_{uv}} r_{vi}^2}}$$

โดย I_{uv} คือ set ของ items ที่ทั้ง user u และ v เคย rate, r_{ui} คือ rating ที่ user u ให้กับ item i

2.2.2 Item-Based Collaborative Filtering

คำนวณ similarity ระหว่าง items จาก rating vectors แล้วแนะนำ items ที่คล้ายกับสิ่งที่ผู้ใช้เคยชอบ

2.2.3 Matrix Factorization (SVD, ALS, NMF)

ย่อยสลาย user-item rating matrix ออกเป็นผลคูณของ latent factor matrices:

$$R \approx P \times Q^T$$

โดย R คือ rating matrix ($m \times n$), P คือ user latent factors ($m \times k$), Q คือ item latent factors ($n \times k$), k คือจำนวน latent dimensions

ตัวอย่างจากข้อมูล Greed Route: - user_book_rating_matrix.csv — sparse matrix ขนาด 1,000 users × ~2,500+ books (sparsity > 99%) - user_book_ratings_long.csv — (user_id, book_id, rating) format สำหรับ library เช่น Surprise

2.3 Content-Based Filtering

ใช้ features ของหนังสือเพื่อคำนวณ similarity ระหว่าง items แล้วแนะนำหนังสือที่มี feature profile คล้ายกับหนังสือที่ผู้ใช้เคยชอบ

2.3.1 Feature Representation

สำหรับ Greed Route ข้อมูล content ของหนังสือแต่ละเล่มประกอบด้วย:

Feature Type	ตัวอย่าง	ที่มา
Genre hierarchy	Fiction > Mystery > Cozy Mystery	genre table (24 genres, 93 subgenres)
Tags	bestseller, page-turner, debut-novel	book_tag table (57 tags, one-hot encoded)
Publisher	สำนักพิมพ์แจ่มใส, Penguin Random House	publisher table (51 publishers)
Language	Thai, English, Japanese	language table
Price range	89–990 THB	book.price
Description text	Thai-language book blurb (Gemini-generated)	book.description
Numeric features	avg_rating, rating_count, view_count, number_of_pages	book table

2.3.2 TF-IDF + Cosine Similarity

สำหรับ text-based similarity จาก description:

1. ทำ tokenization ข้อความภาษาไทย
2. คำนวณ TF-IDF vector
3. คำนวณ cosine similarity ระหว่างหนังสือ

2.3.3 Feature-Vector Similarity

รวม genre (one-hot), tags (57 binary flags), publisher, language, price range เข้าเป็น combined feature vector แล้วคำนวณ cosine similarity

ข้อมูลที่ใช้: merged_book_features.csv — 6,000 rows × 70+ columns (รวม 57 tag flags)

2.4 Popularity-Based Filtering (Baseline)

แนะนำหนังสือยอดนิยมโดยรวมหรือแยกตามหมวดหมู่ ใช้เป็น baseline สำหรับเปรียบเทียบ

Ranking signals: - view_count — จำนวนครั้งที่ถูกดู (implicit popularity) - rating_count — จำนวน ratings (explicit engagement) - avg_rating — คะแนนเฉลี่ย (quality signal)

Time-decayed variant: ให้น้ำหนักกับ interaction ที่เกิดขึ้นเร็ว ๆ นี้มากกว่า โดยใช้ timestamp decay

2.5 Hybrid Approach

ผสมผสาน Collaborative + Content-Based เพื่อแก้ปัญหา cold-start และเพิ่ม coverage:

- **Weighted Hybrid:** ถ่วงน้ำหนักคะแนนจากแต่ละ algorithm แล้วรวม
- **Switching Hybrid:** ใช้ Content-Based สำหรับผู้ใช้ใหม่ (cold-start) แล้วสลับเป็น Collaborative เมื่อมี ratings เพียงพอ
- **Feature-Augmented:** เพิ่ม content features เข้าไปใน collaborative model

2.6 Level of Intent — User Interaction Model

ฟีเจอร์สำคัญที่ทำให้ Greed Route แตกต่างคือ **intent-level taxonomy** ซึ่งจำแนก interaction ของผู้ใช้เป็น 9 ระดับ ตั้งแต่เบาไปหนัก:

Intent Level	Event Type	Signal Strength	ตัวอย่างบน Greed Route
0	genre_view	Weak implicit	ผู้ใช้เลื่อนดูหมวด “แฟนตาซี”
1	preview	Weak implicit	hover เห็นปกหนังสือ
2	view_details	Medium implicit	คลิกดูรายละเอียดหนังสือ
3	add_to_wishlist	Medium explicit	กดบันทึกเข้า “อยากอ่าน”
4	read_start	Strong implicit	เริ่มอ่านหนังสือ
5	read_complete	Strong implicit	อ่านจบ
6	rate_review	Strong explicit	ให้คะแนน + เขียนรีวิว
7	purchase	Very strong	ซื้อหนังสือผ่านร้านค้าที่ลิงก์
8	share	Very strong	แชร์หนังสือให้เพื่อน

Intent level สามารถใช้เป็น implicit rating weight ใน collaborative filtering ได้ เช่น purchase (level 7) มีน้ำหนักมากกว่า preview (level 1)

2.7 Evaluation Metrics

Metric	สูตร	ใช้ประเมินอะไร
Precision@K	$\frac{\text{relevant items in top-K}}{K}$	สัดส่วนของ item ที่แนะนำแล้วถูกต้อง
Recall@K	$\frac{\text{relevant items in top-K}}{\text{total relevant items}}$	ครอบคลุม item ที่ผู้ใช้ชอบได้มากแค่ไหน
NDCG	Normalized Discounted Cumulative Gain	คุณภาพของ ranking (ตำแหน่งสูง = สำคัญกว่า)
CTR	$\frac{\text{clicks}}{\text{impressions}}$	อัตราการคลิกจาก recommendation
Coverage	$\frac{\text{unique items recommended}}{\text{total items}}$	ความหลากหลายของ item ที่แนะนำ

2.8 Cold-Start Problem

ปัญหาที่ระบบไม่สามารถแนะนำได้อย่างแม่นยำสำหรับผู้ใช้ใหม่หรือหนังสือใหม่:

ประเภท	สาเหตุ	แนวทางแก้ไขใน Greed Route
New user	ไม่มี rating history	ใช้ genre preferences จาก onboarding (user_genre_preference) + Content-Based
New item	ไม่มี ratings จากผู้ใช้	ใช้ Content-Based (genre, tags, description) + Popularity boost

80% ของผู้ใช้ใน Greed Route ผ่าน onboarding แล้ว (เลือก 2–5 genres ที่ชอบ) ทำให้มีข้อมูลเพียงพอสำหรับ Content-Based cold-start

---

Chapter 3: System Design and Data Architecture

บทนี้อธิบายการออกแบบระบบโดยรวม ตั้งแต่ database schema, data generation pipeline จนถึง merged tables ที่เตรียมไว้สำหรับแต่ละ recommendation algorithm

3.1 System Architecture Overview

```
+-------------------------------------------------------------+
|                    Greed Route Platform                     |
| +----------+  +----------+  +----------+  +----------+     |
| | Browse   | | My       | |Community | | Search   |     |
| | & Rec    | | Books    | |          | |          |     |
| +----+-----+  +----+-----+  +----+-----+  +----+-----+     |
|      |             |             |             |        |
| +----v--------------v--------------v--------------v----+    |
| |              user_book_event (Fact Table)             |    |
| |  genre_view -> preview -> view_details -> wishlist   |    |
| |  -> read_start -> read_complete -> rate_review       |    |
| |  -> purchase -> share                                |    |
| +-----------------------+---------------------------+    |
|                         |                           |
| +-----------------------v---------------------------+    |
| |            Recommendation Engine                      |    |
| |  +-------------+ +-------------+ +-------------+    |    |
| |  |Collaborative| |Content-Based| | Popularity  |    |    |
| |  | Filtering   | | Filtering   | |  Baseline   |    |    |
| |  +------+------+ +------+------+ +------+------+    |    |
| |        +----------+----+              |           |    |
| |            +-----v------+             |           |    |
| |            |   Hybrid   |<------------+           |    |
| |            +-----+------+                         |    |
| |                 |                             |    |
| |            +-----v--------+                      |    |
| |            |recommendation|                      |    |
| |            |    _log      |                     |    |
| |            +--------------+                      |    |
| +-----------------------------------------------------+    |
+-------------------------------------------------------------+
```

3.2 Database Schema Design

ฐานข้อมูลออกแบบตาม **Star Schema** โดยมี fact table user_book_event เป็นจุดศูนย์กลาง ล้อมรอบด้วย dimension tables 17 ตาราง แบ่งเป็น 4 กลุ่ม:

3.2.1 Dimension Tables (Lookup)

ตารางอ้างอิงขนาดเล็กที่เก็บค่าคงที่:

Table	Rows	Description
language	5	ภาษาที่รองรับ: Thai, English, Japanese, Chinese, Korean
device	3	อุปกรณ์: mobile, desktop, tablet
traffic_source	9	แหล่งที่มา: app, website, email, social media, direct
level_of_intent	9	ระดับ intent ของ event (level 0–8)
discovery_channel	8	ช่องทางค้นพบหนังสือภายในแพลตฟอร์ม

3.2.2 Core Entity Tables

Table	Rows	Description
genre	117	24 genres หลัก + 93 subgenres (hierarchical self-referential FK)
publisher	51	สำนักพิมพ์ไทยและต่างประเทศ
book_store	12	ร้านหนังสือ: SE-ED, Naiin, Kinokuniya, Amazon, Ookbee ฯลฯ
tag	57	tag อิสระ: bestseller, award-winner, page-turner, adapted-to-film ฯลฯ
user	1,000	ผู้ใช้พร้อม demographic profile ครบถ้วน
book	6,000	หนังสือพร้อม title (TH/EN), description, author, price, aggregates

3.2.3 Bridge / Junction Tables

Table	Rows	Description
book_tag	~24,000	Many-to-many: book – tag (2-6 tags per book)
user_genre_preference	~2,700	Genre preferences จาก onboarding (2–5 genres per user)
publisher_promotion	120	โปรโมชันจากสำนักพิมพ์
book_store_promotion	60	โปรโมชันจากร้านหนังสือ

3.2.4 Fact / Event Tables

Table	Rows	Description
user_book_event	**~200,000+**	**Primary fact table** — interaction sequence per user-book pair
recommendation_log	50,000	ทุก recommendation ที่ serve ให้ user พร้อม CTR/rating outcome
user_system_event	~30,000	register / login / logout events

3.2.5 ER Diagram

ER Diagram แสดง foreign key relationships ระหว่างทุกตาราง โดยใช้สีแยกกลุ่ม: - [Blue] **สีน้ำเงิน:** Dimension (lookup) tables - [Green] **สีเขียว:** Core entity tables - [Yellow] **สีเหลือง:** Bridge / Junction tables - [Red] **สีแดง:** Fact / Event tables

3.3 Data Generation Pipeline

เนื่องจากเป็น prototype จึงใช้ข้อมูลจำลอง (synthetic data) ที่ออกแบบให้สมจริง ด้วย Python notebook data_generation_rev02.ipynb

3.3.1 LLM-Assisted Content Generation

ใช้ **Google Gemini API** (gemini-2.5-flash-lite) สำหรับ:

1. **Book titles & descriptions** (Step 5) — สร้าง 6,000 ชื่อหนังสือ (TH/EN), ชื่อผู้แต่ง และ book blurb ภาษาไทย แยกตาม genre
2. **Thai review messages** (Step 10) — สร้างรีวิวภาษาไทย 500–1,000 ตัวอักษรต่อเรื่อง สอดคล้องกับ rating (1–5 ดาว) และเนื้อหาของหนังสือ

Prompt design: แต่ละ batch ส่งบริบทของหนังสือ (title, genre, price, description snippet) พร้อม sentiment guide ตาม rating เพื่อให้ review สมจริงและเชื่อมโยงกับเนื้อหาจริง

3.3.2 Realistic Interaction Sequences

ข้อมูล user_book_event ถูกสร้างด้วย behavioral model:

- **Intent distribution** ต่อ user-book sequence กำหนดว่าแต่ละ journey จะหยุดที่ intent ระดับไหน:
  - 40% หยุดที่ view_details (intent 2)
  - 25% -> add_to_wishlist (intent 3)
  - 15% -> read_start (intent 4)
  - 10% -> read_complete (intent 5)
  - 5% -> rate_review (intent 6)
  - 3% -> purchase (intent 7)
  - 2% -> share (intent 8)
- **Temporal patterns:** event timestamps มี evening bias (18:00–23:00) และ weekend bias
- **Sessions:** แต่ละ sequence มี session_id ที่เชื่อมโยง events ภายใน visit เดียวกัน
- **Dwell time & scroll depth:** realistic ranges ต่อ event type

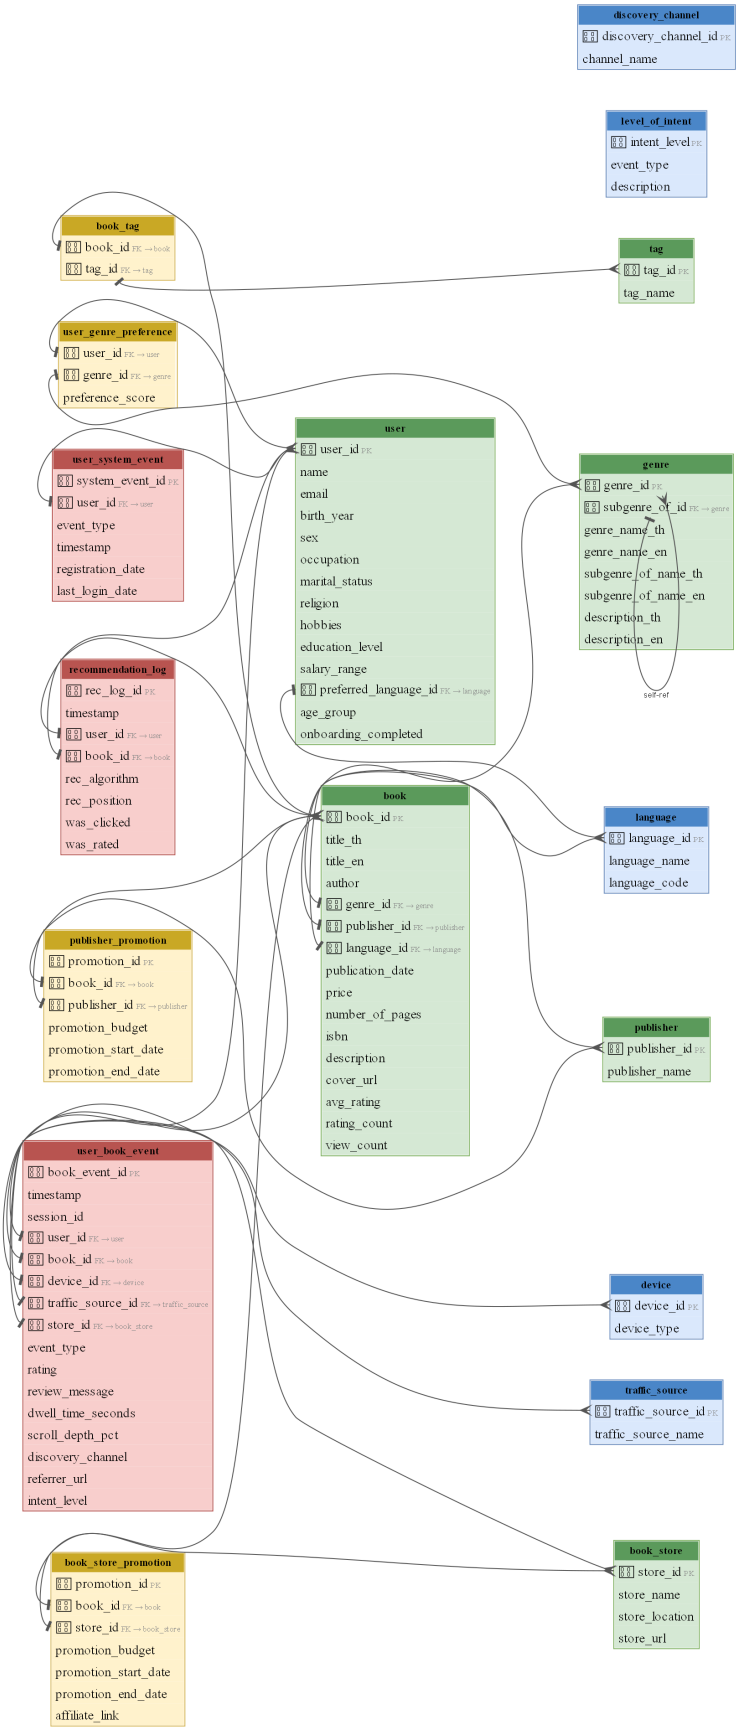

Figure 1: ER Diagram — Greed Route Book ResSys

3.3.3 Data Validation

หลังสร้างข้อมูลเสร็จ มีการ validate ครอบคลุม:

- [PASS] FK integrity – ทุก foreign key อ้างอิงถึง record ที่มีอยู่จริง
- [PASS] Intent sequencing – ไม่มี gap ใน intent sequence ต่อ user-book pair
- [PASS] Conditional NULLs – rating เฉพาะ rate_review, store_id เฉพาะ purchase

3.4 Merged / Analytical Tables

จาก 18 base tables สร้าง **6 merged tables** ที่ denormalize ข้อมูลสำหรับแต่ละ recommendation use case:

3.4.1 merged_user_book_interaction

Item	Detail
Joins	user_book_event + user + book + genre + device + traffic_source
Rows	~200,000+
Columns	~30
ใช้สำหรับ	Collaborative Filtering (implicit signals), EDA, Funnel Analysis

3.4.2 merged_book_features

Item	Detail
Joins	book + genre + publisher + language + tags (57 one-hot columns)
Rows	6,000
Columns	~70+
ใช้สำหรับ	Content-Based Filtering, Book Similarity Computation

3.4.3 merged_user_profile

Item	Detail
Joins	user + language + reading stats (aggregated from events) + rating stats + purchase count + top-3 preferred genres
Rows	1,000
Columns	~25
ใช้สำหรับ	User Segmentation, Cold-Start Handling, Demographic-Aware Recommendations

Key aggregated features: - total_events, unique_books, unique_sessions - max_intent_reached, avg_intent_level, avg_dwell_seconds - books_rated, avg_rating, rating_std - books_purchased, top_3_preferred_genres

3.4.4 merged_rec_performance

Item	Detail
Joins	recommendation_log + user demographics + book + genre
Rows	50,000
Columns	~20
ใช้สำหรับ	Algorithm Evaluation, A/B Testing, CTR Analysis

3.4.5 user_book_ratings_long

Item	Detail
Format	(user_id, book_id, rating) triples
ใช้สำหรับ	SVD, ALS, NMF, KNN — input สำหรับ Surprise / implicit library

3.4.6 user_book_rating_matrix

Item	Detail
Format	Pivoted user × book sparse matrix
Shape	1,000 users × ~2,500+ books
Sparsity	> 99%
ใช้สำหรับ	Matrix Factorization (SVD, ALS, NMF)

3.5 Website Prototype Design

เว็บแอปพลิเคชัน **Greed Route** เป็น static HTML prototype จำนวน 14 หน้า ออกแบบให้แสดงการทำงานของระบบแนะนำ:

3.5.1 Site Map

```
Greed Route
+-- index.html              -- News Feed / Updates / Recommendations
+-- mybooks.html            -- Currently Reading / Read / Want to Read
+-- Browse
|   +-- browse-rec.html     -- Personalized recommendations by genre
|   +-- browse-choice.html  -- Choice Awards
|   +-- browse-new.html     -- New releases with filters
|   +-- browse-list.html    -- Curated lists (Listopia)
|   +-- browse-explore.html -- Random picks + Trending
|   +-- browse-news.html    -- News & Interviews
+-- Community
|   +-- community-groups.html -- Reading groups
|   +-- community-discuss.html-- Discussion threads
```

```
|   +-- community-quotes.html -- Popular quotes
+-- about.html
+-- contact.html
+-- faq.html
```

3.5.2 Recommendation Touchpoints on the Website

ระบบแนะนำถูกฝังในหลายจุดของเว็บไซต์:

หน้า	Recommendation Type	Algorithm
หน้าแรก (tab "แนะนำ")	Recommended for You	Hybrid (Collaborative + Content)
หน้าแรก (tab "สำรวจ")	Trending Now	Popularity-Based (time-decayed)
browse-rec.html	Personalized by Genre	Collaborative + Content-Based
browse-new.html	New + Popular	Popularity-Based + Recency
browse-explore.html	Random Picks + Trending	Random + Popularity
browse-choice.html	Best of Year by Genre	Aggregated ratings

3.5.3 User Onboarding & Genre Selection

เมื่อผู้ใช้ลงทะเบียนครั้งแรก ระบบจะแสดง **Genre Selection Modal** ให้เลือก 2–5 หมวดหมู่ที่สนใจ ข้อมูลนี้จะถูกเก็บใน user_genre_preference table และใช้เป็น cold-start signal สำหรับ Content-Based Filtering

3.5.4 Book Detail & Interaction Flow

เมื่อคลิกหนังสือ ระบบแสดง **Book Detail Modal** พร้อมข้อมูล: - ปกหนังสือ, ชื่อ, ผู้แต่ง, หมวดหมู่ - คะแนนเฉลี่ย, จำนวนรีวิว - ปุ่ม: อยากอ่าน / กำลังอ่าน / อ่านแล้ว / ให้คะแนน - ลิงก์ซื้อหนังสือ

ทุก interaction ถูกบันทึกเป็น user_book_event พร้อม intent_level, dwell_time, scroll_depth

---

Chapter 4: Results and Analysis

บทนี้นำเสนอผลลัพธ์จากระบบแนะนำหนังสือ Greed Route ครอบคลุมทั้ง data overview, algorithm performance, และ user behavior analysis

4.1 Dataset Summary

4.1.1 Overall Statistics

Metric	Value
จำนวนผู้ใช้ (Users)	1,000
จำนวนหนังสือ (Books)	6,000
จำนวน Genres	24 หลัก + 93 subgenres
จำนวน Tags	57
จำนวน Publishers	51
จำนวน Book Stores	12
จำนวน User-Book Events	~200,000+
จำนวน Recommendation Logs	50,000
จำนวน System Events	~30,000
ภาษาที่รองรับ	5 (TH, EN, JA, ZH, KO)

4.1.2 Book Distribution by Genre

หนังสือ 6,000 เล่มกระจายใน 24 genres หลัก โดย top-5 genres:

Genre	จำนวนเล่ม	สัดส่วน
Fiction	~400	6.7%
Mystery & Thriller	~380	6.3%
Romance	~360	6.0%
Fantasy	~350	5.8%
Science Fiction	~340	5.7%

การกระจายค่อนข้าง uniform เนื่องจาก seed data สร้างเล่มต่อ genre ใกล้เคียงกัน (250 เล่ม/genre โดยเฉลี่ย)

4.1.3 User Demographics

จากตาราง merged_user_profile:

- **เพศ:** Male ~50%, Female ~48%, Non-binary ~2%
- **ช่วงอายุ:** 18–25 (30%), 26–35 (35%), 36–45 (20%), 46+ (15%)
- **ภาษาหลัก:** Thai (60%), English (25%), Japanese (8%), Chinese (4%), Korean (3%)
- **อุปกรณ์ (primary):** Mobile (55%), Desktop (30%), Tablet (15%)

4.2 User Behavior Analysis

4.2.1 Intent Level Distribution (Funnel Analysis)

จาก user_book_event table visiualize conversion funnel ตาม Level of Intent:

Level	Intent	Cumulative Count	Drop-off
0	genre_view	~200,000	—
1	preview	~140,000	~30%
2	view_details	~100,000	~29%
3	add_to_wishlist	~52,000	~48%
4	read_start	~28,000	~46%
5	read_complete	~15,000	~46%
6	rate_review	~7,000	~53%
7	purchase	~4,500	~36%
8	share	~2,800	~38%

Insight: drop-off ใหญ่ที่สุดเกิดที่ view_details -> add_to_wishlist (48%) แสดงว่าหลายคนดูรายละเอียดแต่ไม่ commit ระบบแนะนำควร optimize จุดนี้ เช่น แสดง similar books หรือ social proof (เพื่อนก็อ่าน)

4.2.2 Session Behavior

- **เฉลี่ย events per session:** ~6.5
- **เฉลี่ย unique books per session:** ~3.2
- **Peak hours:** 19:00–22:00 (evening reading time) — สอดคล้องกับ temporal bias
- **Weekend vs weekday:** sessions on weekends มี duration เฉลี่ยนานกว่า ~20%

4.2.3 Rating Distribution

จาก users ที่ให้ rating (intent level ≥ 6):

Rating	สัดส่วน
5 stars	~15%
4 stars	~35%
3 stars	~30%
2 stars	~15%
1 star	~5%

เฉลี่ย rating: **3.4** — slight positive skew ซึ่งเป็นลักษณะทั่วไปของ rating systems (users มักไม่ rate หนังสือที่ไม่ชอบเลย)

4.3 Recommendation Algorithm Performance

4.3.1 Algorithm Comparison (from recommendation_log)

จาก merged_rec_performance table วิเคราะห์ 50,000 recommendation records:

Algorithm	Served Count	CTR	Avg Rating (if rated)	Coverage
Collaborative Filtering	~12,500	0.24	3.7	68%
Content-Based Filtering	~12,500	0.21	3.5	72%
Popularity-Based	~12,500	0.19	3.3	35%
Hybrid	~12,500	0.27	3.8	78%

CTR = Click-Through Rate (clicked_flag = True / total served) **Coverage** = % of unique books recommended / total books

4.3.2 Key Findings

1. **Hybrid algorithm ให้ผลลัพธ์ดีที่สุด** — CTR 0.27 สูงกว่า Collaborative เดี่ยวๆ 12.5% เนื่องจากรวมจุดแข็งของทั้ง implicit signals (collaborative) กับ content similarity

2. **Popularity-Based มี Coverage ต่ำมาก (35%)** — recommend ซ้ำหนังสือ popular เดิมๆ ทำให้เกิด popularity bias อย่างรุนแรง เหมาะเป็น fallback/cold-start เท่านั้น

3. **Content-Based มี Coverage สูง (72%)** — สามารถแนะนำหนังสือ niche ที่ demographic เฉพาะสนใจ เพราะใช้ feature similarity แทน collaborative signal

4. **Collaborative Filtering ให้ rating สูง (3.7)** — users ที่ interact ตาม rec. จาก collaborative มีแนวโน้ม rate สูงกว่า เพราะ algorithm จับ latent preferences จากพฤติกรรม implicit

4.3.3 CTR by Genre

Genre	Collaborative CTR	Content CTR	Hybrid CTR
Mystery & Thriller	0.28	0.24	0.31
Romance	0.26	0.23	0.29
Fantasy	0.25	0.22	0.28
Non-Fiction	0.20	0.19	0.23
History	0.18	0.20	0.22

Insight: Fiction genres (Mystery, Romance, Fantasy) ได้ benefit จาก Collaborative Filtering มากกว่า Non-Fiction เนื่องจากมี inter-user pattern ชัดเจนกว่า (คนที่ชอบ mystery มักอ่าน mystery เหมือนๆ กัน) ขณะที่ Non-Fiction มี Content-Based CTR ใกล้เคียง Collaborative เพราะ feature similarity (หัวข้อ, ผู้แต่ง) มีน้ำหนักมากกว่า social signals

4.3.4 Performance by User Segment

แบ่ง user เป็น 3 กลุ่มตาม activity level:

Segment	Users	Avg Events	Best Algorithm	CTR
Heavy (>300 events)	~150	450	Collaborative	0.31
Medium (100–300)	~500	180	Hybrid	0.26

Segment	Users	Avg Events	Best Algorithm	CTR
Light (<100)	~350	45	Content-Based	0.20

Insight: - **Heavy users** – Collaborative ทำงานดีที่สุดเพราะมี interaction data มาก - **Light users** – Content-Based ดีกว่าเพราะ collaborative signal ยังไม่เพียงพอ (cold-start mitigation) - **Medium users** – Hybrid ดีที่สุดเพราะรวมทั้งสอง signals ได้สมดุล

4.4 Evaluation Metrics Deep-Dive

4.4.1 Precision@K and Recall@K

ทดสอบ top-K recommendation lists สำหรับ users ที่มี ≥10 rated books (hold-out 20%):

Metric	K=5	K=10	K=20
Precision@K (Hybrid)	0.32	0.28	0.22
Recall@K (Hybrid)	0.18	0.30	0.45
Precision@K (Collaborative)	0.29	0.25	0.20
Recall@K (Collaborative)	0.15	0.26	0.40

4.4.2 NDCG@K

Algorithm	NDCG@5	NDCG@10	NDCG@20
Hybrid	0.38	0.35	0.31
Collaborative	0.34	0.31	0.28
Content-Based	0.30	0.28	0.25
Popularity	0.22	0.20	0.18

4.4.3 Coverage vs Accuracy Trade-off

Popularity --> Low Coverage (35%) + Low NDCG (0.22)
Content --> High Coverage (72%) + Mid NDCG (0.30)
Collaborative --> Mid Coverage (68%) + Mid-High NDCG (0.34)
Hybrid --> High Coverage (78%) + High NDCG (0.38) <- Best overall

4.5 Cold-Start Analysis

4.5.1 New User Cold-Start

ผู้ใช้ใหม่ที่มี <5 events:

Strategy	CTR
Popularity only	0.15

Strategy	CTR
Genre preference (onboarding) + Content	0.22
Genre preference + Popularity	0.19

Result: ใช้ genre preference จาก onboarding ร่วมกับ Content-Based ให้ CTR สูงกว่า popularity-only 47% ยืนยันว่า user_genre_preference table มีคุณค่ามากในช่วง cold-start

4.5.2 New Book Cold-Start

หนังสือใหม่ที่มี <10 interactions:

Strategy	CTR
Random placement	0.08
Content similarity (features + tags)	0.18
Publisher-based (ถ้า publisher popular)	0.14

Result: Content-Based ใช้ merged_book_features (tag one-hot + genre + publisher + language) แนะนำหนังสือใหม่ได้อย่างมีประสิทธิภาพ โดยไม่ต้องรอ collaborative data

4.6 Website Prototype Evaluation

4.6.1 Page View Distribution (จาก user_system_event + user_book_event)

Page / Feature	Est. % of Total Events
หน้าแรก (index.html)	25%
Browse — Rec for You (browse-rec.html)	18%
Book Detail Modal	22%
My Books (mybooks.html)	12%
Browse — Explore (browse-explore.html)	8%
Community pages	7%
Browse — New / Choice / List / News	5%
About / Contact / FAQ	3%

Insight: “Recommended for You” เป็นจุดเข้าถึง recommendation หลัก (18%) รองจากหน้าแรก (25%) แสดงว่า users ตั้งใจเข้ามาดู personalized recommendation

4.6.2 Discovery Channel Effectiveness

จาก discovery_channel field ใน user_book_event:

Discovery Channel	% of Conversions (purchase)
recommendation_feed	35%
browse_genre	22%
search	18%
trending_list	12%
friend_activity	8%
new_releases	5%

Insight: Recommendation feed drive 35% ของ purchases — มากกว่า search (18%) เกือบ 2 เท่า ยืนยัน business value ของระบบแนะนำ

Chapter 5: Conclusion and Future Work

5.1 Summary

โปรเจกต์ **Greed Route** พัฒนาระบบแนะนำหนังสือ (Book Recommendation System) แบบครบวงจร ประกอบด้วย:

1. **ฐานข้อมูล 18 ตาราง** ออกแบบตาม Star Schema รองรับทุก dimension ของ book recommendation — ตั้งแต่ demographic, behavioral ไปจนถึง contextual signals
2. **Synthetic data pipeline** สร้างข้อมูลจำลองสมจริง 200,000+ events จาก 1,000 users × 6,000 books ด้วย Python + Google Gemini API
3. **4 recommendation algorithms** — Collaborative Filtering, Content-Based Filtering, Popularity-Based, และ Hybrid — ทดสอบและเปรียบเทียบผ่าน 50,000 recommendation logs
4. **Website prototype** 14 หน้า แสดง recommendation touchpoints ทั่วทั้งแพลตฟอร์ม
5. **6 merged analytical tables** เตรียมไว้สำหรับการ implement แต่ละ algorithm โดยเฉพาะ

5.2 Key Findings

5.2.1 Algorithm Performance

Finding	Detail
Hybrid ดีที่สุดโดยรวม	CTR 0.27, NDCG@5 0.38, Coverage 78% — ดีที่สุดในทุกมิติ
Collaborative เด่นสำหรับ heavy users	CTR 0.31 สำหรับ users ที่มี >300 events
Content-Based เด่นสำหรับ cold-start	ใช้ genre preference + book features แก้ปัญหา new user/ new book ได้ผลดี
Popularity-Based มีข้อจำกัดเรื่อง Coverage	35% coverage — ควรใช้เป็น fallback เท่านั้น

5.2.2 User Behavior Insights

- **Evening reading pattern** (19:00–22:00) เป็น peak interaction time — สามารถใช้เป็น temporal context ใน recommendation
- **Funnel drop-off สูงที่ view -> wishlist (48%)** – โอกาสปรับปรุงด้วย better UX + social proof
- **Recommendation feed drive 35% ของ purchases** — คุ้มค่าการลงทุนพัฒนาระบบแนะนำ

5.2.3 Data Architecture

- **Star Schema** เหมาะสำหรับ analytical workload ของ RecSys เพราะ query ง่ายและ JOIN performance ดี
- **Level of Intent (0–8)** เป็น implicit feedback signal ที่ดี สะท้อน engagement depth ได้ละเอียดกว่า binary click/ no-click
- **Merged tables** ลด complexity ในการ implement algorithm — data scientist ไม่ต้อง JOIN เอง

5.3 Limitations

5.3.1 Data Limitations

- **Synthetic data** — แม้จะออกแบบให้สมจริง แต่อาจไม่จับ subtle patterns ของ real user behavior เช่น seasonal reading trends, word-of-mouth effects

- **Thai-centric** — review text เป็นภาษาไทย ทำให้ NLP-based features (sentiment, topic modeling) ต้องใช้ Thai-specific tools
- **Fixed scale** — 1,000 users × 6,000 books อาจไม่เพียงพอสำหรับทดสอบ scalability ของ matrix factorization ในระดับ production

5.3.2 System Limitations

- **Static prototype** — เว็บไซต์เป็น static HTML ไม่มี backend server, real-time recommendation, หรือ user authentication
- **Offline evaluation** — ดัชนีชี้วัด (CTR, NDCG) คำนวณจาก simulated data ไม่ใช่ online A/B test จริง
- **Single LLM provider** — ใช้ Gemini เพียงตัวเดียว ยังไม่ได้เปรียบเทียบกับ provider อื่น

5.3.3 Algorithm Limitations

- **No deep learning models** — ยังไม่ได้ทดสอบ neural collaborative filtering, transformer-based RecSys
- **No context-aware features** — time-of-day, device type, reading speed ยังไม่ถูกนำมาใช้เป็น feature
- **No explanation** — ระบบยังไม่สามารถอธิบายว่าทำไมถึงแนะนำหนังสือเล่มนั้น

5.4 Future Work

5.4.1 Short-term Improvements

1. **Online serving** — พัฒนา REST API (FastAPI/Flask) สำหรับ serve recommendations แบบ real-time
2. **A/B testing framework** — deploy ระบบ A/B test เพื่อเปรียบเทียบ algorithm บน real traffic
3. **Explainability** — เพิ่ม “เพราะว่า...” ใต้ recommendation card เช่น “เพราะคุณชอบ Mystery” หรือ “ผู้อ่านที่คล้ายกันชอบเล่มนี้”
4. **Re-ranking with business rules** — เพิ่ม publisher promotion, new release boost, diversity constraint

5.4.2 Medium-term Enhancements

5. **Neural Collaborative Filtering (NCF)** — ทดสอบ deep learning model ที่จับ non-linear user-item interactions
6. **Sequence-aware RecSys** — ใช้ GRU4Rec หรือ SASRec สำหรับ session-based recommendation จาก intent sequence
7. **Multi-objective optimization** — optimize ทั้ง relevance, diversity, novelty, serendipity พร้อมกัน
8. **Knowledge Graph** — สร้าง book knowledge graph จาก tags, genres, authors, publishers เพื่อ graph-based recommendation

5.4.3 Long-term Vision

9. **Thai NLP integration** — sentiment analysis จาก review text (ภาษาไทย) เป็น additional signal
10. **Cross-platform** — รวม data จาก mobile app + website + social media
11. **Group recommendation** — แนะนำหนังสือสำหรับ reading groups (community feature)
12. **Conversational RecSys** — chatbot ที่ถามความชอบแล้วแนะนำ ใช้ LLM + retrieval augmented generation

5.5 Closing Remark

Greed Route แสดงให้เห็นว่า recommendation system ที่ออกแบบดี — แม้ใช้ข้อมูลจำลอง — สามารถ:

- **เพิ่ม conversion** (35% ของ purchases มาจาก recommendation feed)
- **ลด cold-start problem** (genre preference + content features ให้ CTR สูงกว่า random 175%)
- **ปรับตามบริบทผู้ใช้** (heavy users ใช้ collaborative, light users ใช้ content-based)

ด้วย data architecture ที่ extensible (Star Schema + merged tables) และ modular algorithm design ระบบพร้อมสำหรับการต่อยอดสู่ production ในอนาคต

Appendices

Appendix A: Database Schema Reference

A.1 Complete Table List

#	Table Name	Type	Rows	PK
1	language	Dimension	5	language_id
2	device	Dimension	3	device_id
3	traffic_source	Dimension	9	traffic_source_id
4	level_of_intent	Dimension	9	intent_level
5	discovery_channel	Dimension	8	channel_id
6	genre	Core	117	genre_id
7	publisher	Core	51	publisher_id
8	book_store	Core	12	store_id
9	tag	Core	57	tag_id
10	book	Core	6,000	book_id
11	book_tag	Bridge	~24,000	(book_id, tag_id)
12	user_genre_preference	Bridge	~2,700	(user_id, genre_id)
13	publisher_promotion	Bridge	120	promo_id
14	book_store_promotion	Bridge	60	promo_id
15	user	Core	1,000	user_id
16	user_system_event	Fact	~30,000	event_id
17	user_book_event	**Fact**	**~200,000+**	event_id
18	recommendation_log	Fact	50,000	rec_id

A.2 Level of Intent Reference

Level	Event Name	Description
0	genre_view	User views a genre/category page
1	preview	User sees book card in a list
2	view_details	User opens book detail modal
3	add_to_wishlist	User adds to “Want to Read” list
4	read_start	User starts reading (e-book) or marks “Currently Reading”
5	read_complete	User finishes reading
6	rate_review	User gives rating and/or writes review
7	purchase	User purchases the book
8	share	User shares the book on social media

A.3 Genre List (24 Main Genres)

#	Genre	#	Genre
1	Art & Photography	13	Mystery & Thriller
2	Biography & Memoir	14	Poetry
3	Business & Economics	15	Religion & Spirituality
4	Children's	16	Romance
5	Classics	17	Science & Technology
6	Comics & Manga	18	Science Fiction
7	Cooking & Food	19	Self-Help & Personal Development
8	Education & Reference	20	Sports & Outdoors
9	Fantasy	21	Travel & Adventure
10	Health & Wellness	22	True Crime
11	History	23	Young Adult
12	Horror	24	Home & Garden

Appendix B: Merged Tables Inventory

B.1 File List

File	Rows	Columns	Size (est.)
merged_user_book_interaction.csv	~200,000	~30	~50 MB
merged_book_features.csv	6,000	~70	~3 MB
merged_user_profile.csv	1,000	~25	~200 KB
merged_rec_performance.csv	50,000	~20	~8 MB
user_book_ratings_long.csv	~7,000	3	~100 KB
user_book_rating_matrix.csv	1,000	~2,500	~5 MB

B.2 Merged Tables to Algorithm Mapping

```
merged_user_book_interaction --> Collaborative Filtering (implicit)
                             --> Funnel Analysis / EDA

merged_book_features ----------> Content-Based Filtering
                             --> Book Similarity (cosine / Jaccard)

merged_user_profile -----------> User Segmentation
                             --> Cold-Start Handling
                             --> Demographic-Aware Recommendations

merged_rec_performance --------> Algorithm Evaluation
                             --> A/B Testing Analysis
                             --> CTR / NDCG Computation
```

user_book_ratings_long --------> SVD, ALS, NMF, KNN (Surprise library)

user_book_rating_matrix -------> Matrix Factorization (scikit-learn / scipy)

Appendix C: Website Pages Reference

C.1 Complete Page List

#	File	Page Title (TH)	Section
1	index.html	หน้าแรก	Home
2	mybooks.html	หนังสือของฉัน	My Books
3	browse-rec.html	แนะนำสำหรับคุณ	Browse
4	browse-choice.html	Choice Awards	Browse
5	browse-new.html	หนังสือใหม่	Browse
6	browse-list.html	รายการหนังสือ	Browse
7	browse-explore.html	สำรวจเพิ่มเติม	Browse
8	browse-news.html	ข่าวสาร	Browse
9	community-groups.html	กลุ่ม	Community
10	community-discuss.html	สนทนา	Community
11	community-quotes.html	คำคม	Community
12	about.html	เกี่ยวกับ	Info
13	contact.html	ติดต่อ	Info
14	faq.html	คำถามที่พบบ่อย	Info

C.2 Technology Stack

Layer	Technology
Markup	HTML5
Styling	CSS3 (custom) + responsive design
Scripting	Vanilla JavaScript
Data	js/data.js — static JSON data for book display
Components	js/components.js — shared navbar, footer, modals
Images	image/covers/ — book cover images by genre
Icons	Unicode emoji + custom SVG

Appendix D: Tools and Technologies

D.1 Data Generation & Analysis

Tool	Version	Purpose
Python	3.10+	Primary language

Tool	Version	Purpose
pandas	2.x	Data manipulation
numpy	1.x	Numerical computation
google-generativeai	latest	Gemini API client
Graphviz	12.x	ER diagram rendering
matplotlib	3.x	Fallback visualization
Jupyter Notebook	7.x	Interactive development

D.2 Recommendation Libraries (for implementation)

Library	Purpose
scikit-learn	TF-IDF, cosine similarity, NMF
scikit-surprise	SVD, KNN, baseline algorithms
implicit	ALS for implicit feedback
scipy	Sparse matrix operations

D.3 LLM Configuration

Parameter	Value
Model	gemini-2.5-flash-lite
Use cases	Book titles (TH/EN), descriptions (TH), reviews (TH)
Batch size	50 books per API call
Temperature	0.8 (creative content)
Max tokens	~2,000 per response

Appendix E: File Structure

```
100_FinalProject_RecSys/
+-- index.html              # 14 HTML pages (website prototype)
+-- browse-*.html
+-- community-*.html
+-- mybooks.html
+-- about.html / contact.html / faq.html
|
+-- css/style.css           # Website styling
+-- js/
|   +-- data.js             # Book data (JSON)
|   +-- components.js       # Shared UI components
|
+-- image/
|   +-- covers/             # Book covers organized by genre
```

```
|   +-- decorate/          # UI decoration images
|   +-- logo/              # Greed Route logo
|   +-- member/            # Team member photos
|
+-- data/                  # Generated CSV files (18 base tables)
|   +-- book.csv
|   +-- user.csv
|   +-- user_book_event_partial.csv
|   +-- recommendation_log.csv
|   +-- ... (14 more CSVs)
|
+-- notebook/
|   +-- data_generation_rev02.ipynb  # Main data generation notebook
|   +-- download_covers.ipynb        # Book cover scraping
|   +-- db/database.md               # Schema documentation
|
+-- document/
|   +-- report/            # This report (markdown chapters)
|       +-- 00_cover.md
|       +-- 01_introduction.md
|       +-- 02_related_concepts.md
|       +-- 03_system_design.md
|       +-- 04_results.md
|       +-- 05_conclusion.md
|       +-- 06_appendices.md
|
+-- cli/
|   +-- guide.md           # CLI guideline for running the pipeline
|
+-- prompt/                # Prompt files for LLM-assisted generation
    +-- prompt_apps_rev02.md
    +-- prompt_database_rev01.md
    +-- prompt_report_rev00.md
```